



Lecture 7 KKT与对偶

- 1 约束优化一阶最优性条件 (KKT)
- 2 凸优化最优性条件
- 3 对偶规划与对偶理论



一阶最优性条件

约束优化模型

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, \quad i = 1, 2, \dots, m \quad \text{--- 不等式约束} \\ & h_j(x) = 0, \quad j = 1, 2, \dots, l \quad \text{--- 等式约束} \\ & x \in R^n \end{aligned}$$

可行域(集):
$$S = \left\{ x \in R^n \left| \begin{array}{ll} g_i(x) \geq 0, & i = 1, 2, \dots, m \\ h_j(x) = 0, & j = 1, 2, \dots, l \end{array} \right. \right\}$$



一阶最优性条件

可行方向

定义1 设集合 $S \subset \mathbb{R}^n$, $\bar{x} \in cl S$ 以及向量 $d \neq 0$, 若存在 $\delta > 0$, 使得对于任意 $\lambda \in (0, \delta)$, 有 $\bar{x} + \lambda d \in S$, 则称 d 为集合 S 在 \bar{x} 处的一个可行方向 (feasible direction) .

■ 可行方向锥(集): $\bar{x} \in cl S$

$$D = \{d \mid d \neq 0, \exists \delta > 0, \forall \lambda \in (0, \delta), \text{有 } \bar{x} + \lambda d \in S\}$$



一阶最优性条件

下降方向 (回顾)

定义2 设 $\bar{\mathbf{x}}, \mathbf{d} \in \mathbb{R}^n$ 且 $\mathbf{d} \neq 0$, 若存在 $\delta > 0$, 对于任意 $t \in (0, \delta]$, 有 $f(\bar{\mathbf{x}} + t\mathbf{d}) < f(\bar{\mathbf{x}})$, 则称 \mathbf{d} 是函数 f 在 $\bar{\mathbf{x}}$ 处的一个下降方向.

■ 下降方向锥(集):

$$F_0 = \left\{ \mathbf{d} \mid \nabla f(\bar{\mathbf{x}})^T \mathbf{d} < 0 \right\}$$

一阶最优性条件


例1 $\min f(x) = x_1 + x_2$
 $s.t. \quad g(x) = 1 - x_1^2 - x_2^2 \geq 0$

■ 对于任意内点 x^1 ,
可行方向锥 $D = R^2 \setminus \{0\}$
目标函数下降方向锥 $F_0 = \{d \in R^2 \mid d_1 + d_2 < 0\}$

■ 对于边界点 $x^2 = (-1, 0)^T$,
可行方向锥: $D = \{d \in R^2 \mid d_1 > 0\}$;
目标函数下降方向锥 $F_0 = \{d \in R^2 \mid d_1 + d_2 < 0\}$

■ 最优解: $x^3 = \left(-\frac{\sqrt{2}}{2}, -\frac{\sqrt{2}}{2}\right)^T$,

可行方向锥: $D = \{d \in R^2 \mid d_1 + d_2 > 0\}$;
目标函数下降方向锥 $F_0 = \{d \in R^2 \mid d_1 + d_2 < 0\}$



最优解处不存在可行且下降的方向!

$$D \cap F_0 = \emptyset$$



一阶最优性条件

几何最优性条件

定理1 设考虑约束优化问题 $\min_{x \in S} f(x)$, 其中 $S \subset \mathbb{R}^n$ 为非空集合, $\bar{x} \in S$,

f 在 \bar{x} 处可微. 若 \bar{x} 是该问题的一个局部最优解, 则 $D \cap F_0 = \emptyset$.

局部最优解处不存在可行且下降的方向!

证明: 反证法假设存在 $d \in F_0 \cap D$, 则 $d \in F_0, d \in D$.

$\because d \in F_0, \therefore \exists \delta_1 > 0$, 对 $\forall \lambda \in (0, \delta_1)$, 有 $f(\bar{x} + \lambda d) < f(\bar{x})$;

$\because d \in D, \therefore \exists \delta_2 > 0$, 对 $\forall \lambda \in (0, \delta_2)$, 有 $\bar{x} + \lambda d \in S$.

取 $\delta = \min(\delta_1, \delta_2)$, 则当 $\lambda \in (0, \delta)$, 有 $\bar{x} + \lambda d \in S$ 且 $f(\bar{x} + \lambda d) < f(\bar{x})$,

与 \bar{x} 为局部最优解矛盾。

一阶最优性条件

几何最优性条件

定理1 设考虑约束优化问题 $\min_{x \in S} f(x)$, 其中 $S \subset \mathbb{R}^n$ 为非空集合, $\bar{x} \in S$, f 在 \bar{x} 处可微. 若 \bar{x} 是该问题的一个局部最优解, 则 $D \cap F_0 = \emptyset$.

局部最优解处不存在可行且下降的方向!

问题: 如何判断 $D \cap F_0 = \emptyset$



$$F_0 = \left\{ d \mid \nabla f(\bar{x})^T d < 0 \right\}$$

$$D = \left\{ d \mid d \neq 0, \bar{x} \in clS, \exists \delta > 0, \forall \lambda \in (0, \delta), \text{有 } \bar{x} + \lambda d \in S \right\}$$

一阶最优性条件

不等式约束优化

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, i = 1, \dots, m \end{aligned} \quad (1)$$

可行域: $S = \{x \mid g_i(x) \geq 0, i = 1, \dots, m\}$

积极约束: 定义: 若问题(1)的一个可行点 \bar{x} (即 $\bar{x} \in S$)使某个不等式约束 $g_i(x) \geq 0$ 变成等式, 即 $g_i(\bar{x}) = 0$, 则该不等式约束称为关于可行点 \bar{x} 的起作用约束(积极约束); 否则, 若 \bar{x} 使得某个 $g_i(\bar{x}) > 0$, 则该不等式约束称为关于可行点 \bar{x} 的不起作用约束(非积极约束)。

一阶最优性条件

不等式约束优化

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, i = 1, \dots, m \end{aligned} \quad (1)$$

可行域: $S = \{x \mid g_i(x) \geq 0, i = 1, \dots, m\}$

局部约束方向锥:

积极约束指标集

$\bar{x} \in S$, 记 $I := \{i \mid g_i(\bar{x}) = 0\}$, $G_0 = \{d \mid \nabla g_i(\bar{x})^T d > 0, i \in I\}$

称 G_0 为 S 在点 \bar{x} 处的局部约束方向锥(或内方向锥)。



一阶最优性条件

几何条件

定理2: 设 $\bar{x} \in S$, $f(x)$ 和 $g_i(x)(i \in I)$ 在 \bar{x} 处可微, $g_i(x)(i \notin I)$ 在 \bar{x} 处连续, 如果 \bar{x} 是问题(1)的局部最优解, 则 $F_0 \cap G_0 = \emptyset$ 。

一阶最优性条件

问题：如何判断 $G_0 \cap F_0 = \emptyset$



$$F_0 = \left\{ d \mid \nabla f(\bar{x})^T d < 0 \right\} \quad G_0 = \left\{ d \mid -\nabla g_i(\bar{x})^T d < 0, i \in I \right\}$$

凸分析基础：Gordan定理

设 A 为 $m \times n$ 矩阵，那么 $Ax < 0$ 有解的充要条件是不存在非零向量 $y \geq 0$ ，使得 $A^T y = 0$ 。



一阶最优性条件

代数条件

定理3(*Fritz John*条件) 设 $\bar{x} \in S, I = \{i \mid g_i(\bar{x}) = 0\}, f(x), g_i(x)(i \in I)$ 在 \bar{x} 处可微, $g_i(x)(i \notin I)$ 在 \bar{x} 处连续, 若 \bar{x} 是问题(1)的局部最优解, 则存在不全为零的数 $w_0, w_i(i \in I)$, 使得

$$\begin{cases} w_0 \nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) = 0 \\ w_0, w_i \geq 0, \quad i \in I. \end{cases}$$

称 \bar{x} 为问题(1)的*Fritz John 点*(即满足Fritz John条件的点).

一阶最优性条件



Fritz John
(1910 - 1994)

John F., “Extremum Problems with Inequalities as Subsidiary Conditions” ,Studies and Essays, Courant Anniversary Volume, Interscience, New York, 1948.

一阶最优性条件

定理4(*Fritz John*条件) 设 $\bar{x} \in S, I = \{i \mid g_i(\bar{x}) = 0\}$,
 $f(x), g_i(x)$ 在 \bar{x} 处可微, 若 \bar{x} 是问题(1)的局部最优解, 则存在不全为零的数 w_0, w_1, \dots, w_m , 使得

$$\begin{cases} w_0 \nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) = 0 \\ w_i g_i(\bar{x}) = 0, \quad i = 1, 2, \dots, m \\ w_0, w_i \geq 0, \quad i = 1, 2, \dots, m \end{cases}$$

取非积极约束对应的 $w_i = 0$


互补松弛条件

一阶最优性条件

例3 考虑非线性优化问题:

$$\begin{aligned} \min \quad & -x_1 \\ \text{s.t.} \quad & g_1(x) = -x_2 + (1 - x_1)^3 \geq 0 \\ & g_2(x) = x_2 \geq 0 \end{aligned}$$

试判断 $x^{(1)} = (1, 0)^T$ 是否为该问题的Fritz John点.



一阶最优性条件

解: $\because \nabla f(x) = (-1, 0)^T$

$$\nabla g_1(x) = (-3(1-x_1)^2, -1)^T, \nabla g_2(x) = (0, 1)^T$$

在点 $x^{(1)} = (1, 0)^T$ 处, $I = \{1, 2\}$


$$\nabla f(x^{(1)}) = (-1, 0)^T, \nabla g_1(x^{(1)}) = (0, -1)^T,$$

$$\nabla g_2(x^{(1)}) = (0, 1)^T, \text{ 设有}$$

$$w_0 \begin{pmatrix} -1 \\ 0 \end{pmatrix} - w_1 \begin{pmatrix} 0 \\ -1 \end{pmatrix} - w_2 \begin{pmatrix} 0 \\ 1 \end{pmatrix} = 0$$

$$\Rightarrow w_0 = 0, \text{ 取 } w_1 = w_2 > 0$$

$\Rightarrow x^{(1)} = (1, 0)^T$ 是 Fritz John 点。该 Fritz John 点亦是全局最优解！





一阶最优性条件

例4 考虑非线性优化问题:

$$\min f(x) = (x_1 - 1)^2 + (x_2 - 1)^2$$

$$s.t. \quad g_1(x) = (1 - x_1 - x_2)^3 \geq 0$$

$$g_2(x) = x_1 \geq 0$$

$$g_3(x) = x_2 \geq 0$$

唯一最优解: $x^* = \left(\frac{1}{2}, \frac{1}{2}\right)^T$

\therefore 直线 $x_1 + x_2 = 1$ 上所有可行点 \bar{x} 使 $\nabla g_1(\bar{x}) = 0$,

\therefore 取 $w_0 = 0, w_1 = a > 0, w_2 = w_3 = 0$, 总有

$$w_0 \nabla f(\bar{x}) - w_1 \nabla g_1(\bar{x}) - w_2 \nabla g_2(\bar{x}) - w_3 \nabla g_3(\bar{x}) = 0$$

说明在直线 $x_1 + x_2 = 1$ 上每个可行点 \bar{x} 都是 *Fritz John*

点, 但除 x^* 外, 都不是最优解。

Fritz John点不一定是最优解

此时Fritz John条件中实际上不包含目标函数的任何数据



一阶最优性条件

KKT条件

定理5. 考虑问题
$$\begin{cases} \min f(x) \\ \text{s.t. } g_i(x) \geq 0, i = 1, \dots, m \end{cases}$$
 设 $\bar{x} \in S, f, g_i (i \in I)$ 在 \bar{x} 处可微,

$g_i (i \notin I)$ 在 \bar{x} 连续, $\{\nabla g_i(\bar{x}) | i \in I\}$ 线性无关, 若 \bar{x} 是局部最优解, 则存在非负数 $w_i, i \in I$, 使得

$$\nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) = 0.$$

约束规格 (Constraint Qualification)



一阶最优性条件

KKT条件

证明：由定理3，存在不全为零的非负数

$w_0, w'_i, i \in I$ ，使得

$$w_0 \nabla f(\bar{x}) - \sum_{i \in I} w'_i \nabla g_i(\bar{x}) = 0.$$

显然 $w_0 \neq 0$ ，否则 $\nabla g_i(\bar{x}) (i \in I)$ 线性相关，矛盾。

于是，令 $w_i = \frac{w'_i}{w_0} \geq 0 (i \in I)$ ，得

$$\nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) = 0.$$

一阶最优性条件

KKT条件

定理6. 考虑问题
$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \end{cases}$$

设 $\bar{x} \in S$, f, g_i 在 \bar{x} 可微, $\{\nabla g_i(\bar{x}) | i \in I\}$ 线性无关,

若 \bar{x} 是局部最优解, 则存在数 $w_i, i = 1, 2, \dots, m$, 使得

$$\nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) = 0$$

$$w_i g_i(\bar{x}) = 0 \quad i = 1, 2, \dots, m$$

$$w_i \geq 0 \quad i = 1, 2, \dots, m.$$

取非积极约束对应的 $w_i = 0$

互补松弛条件

一阶最优性条件

KKT条件 现代非线性优化兴起的标志性工作!

Karush 1939, Kuhn&Tucker 1951



William Karush
(1917-1997)



Harold William Kuhn
1925 - 2014




Albert William Tucker
1905 - 1995

一阶最优性条件

例5 考虑非线性优化问题:

$$\begin{aligned} \min \quad & (x_1 - 2)^2 + x_2^2 \\ \text{s. t.} \quad & g_1(x) = x_1 - x_2^2 \geq 0 \\ & g_2(x) = -x_1 + x_2 \geq 0 \end{aligned}$$

试判断 $x^{(1)} = (0, 0)^T$,
 $x^{(2)} = (1, 1)^T$ 是否为
该问题的KKT点.



$$\nabla f(x) = \begin{bmatrix} 2(x_1 - 2) \\ 2x_2 \end{bmatrix}, \nabla g_1(x) = \begin{bmatrix} 1 \\ -2x_2 \end{bmatrix}, \nabla g_2(x) = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

一阶最优性条件

例6 求如下不等式约束优化问题的**KKT**点:

$$\min f(x) = x_1^2 + x_2^2 - 6x_1 - 6x_2 + 10$$

$$\text{s. t. } g_1(x) = 4 - x_1 - x_2 \geq 0$$

$$g_2(x) = x_1 \geq 0$$

$$g_3(x) = x_2 \geq 0$$

解: $\nabla f(x) = 2 \begin{bmatrix} x_1 - 3 \\ x_2 - 3 \end{bmatrix}$

$$\nabla g_1(x) = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \quad \nabla g_2(x) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \nabla g_3(x) = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

一阶最优性条件

由 KKT 条件得
$$\begin{bmatrix} x_1 - 3 \\ x_2 - 3 \end{bmatrix} - \lambda_1 \begin{bmatrix} -1 \\ -1 \end{bmatrix} - \lambda_2 \begin{bmatrix} 1 \\ 0 \end{bmatrix} - \lambda_3 \begin{bmatrix} 0 \\ 1 \end{bmatrix} = 0$$

由 KKT 条件及约束条件得
$$\begin{cases} x_1 + \lambda_1 - \lambda_2 = 3 \\ x_2 + \lambda_1 - \lambda_3 = 3 \\ \lambda_1(4 - x_1 - x_2) = 0 \\ \lambda_2 x_1 = 0 \\ \lambda_3 x_2 = 0 \\ x_1 + x_2 \leq 4 \\ \lambda_1, \lambda_2, \lambda_3, x_1, x_2 \geq 0 \end{cases}$$

一阶最优性条件

(1) 若 $x_1 = x_2 = 0$: 由 $\lambda_1(4 - x_1 - x_2) = 0$ 可得 $\lambda_1 = 0$ 。

$\therefore \lambda_1 - \lambda_2 = 3 \Rightarrow \lambda_2 = -3$ 这与 $\lambda_2 \geq 0$ 矛盾。

(2) 若 $x_1 = 0, x_2 \neq 0$: $\therefore \lambda_3 = 0$

$\therefore \begin{cases} x_2 + \lambda_1 = 3 \\ \lambda_1 - \lambda_2 = 3 \end{cases} \Rightarrow x_2 + \lambda_2 = 0 \Rightarrow \lambda_2 = -x_2 < 0$
这与 $\lambda_2 \geq 0$ 矛盾。

(3) 若 $x_1 \neq 0, x_2 = 0$: $\therefore \lambda_2 = 0$

$\therefore \begin{cases} x_1 + \lambda_1 = 3 \\ \lambda_1 - \lambda_3 = 3 \end{cases} \Rightarrow x_1 + \lambda_3 = 0 \Rightarrow \lambda_3 = -x_1 < 0$
这与 $\lambda_3 \geq 0$ 矛盾。

一阶最优性条件

(4) 若 $x_1 \neq 0, x_2 \neq 0$: $\therefore \lambda_2 = \lambda_3 = 0$

$$\therefore \begin{cases} x_1 + \lambda_1 = 3 \\ x_2 + \lambda_1 = 3 \end{cases} \Rightarrow x_1 = x_2$$

若 $x_1 + x_2 < 4 \Rightarrow \lambda_1 = 0 \Rightarrow x_1 = x_2 = 3$

$\Rightarrow x_1 + x_2 = 6 > 4 \Rightarrow$ 矛盾。

$\therefore x_1 + x_2 = 4 \Rightarrow x_1 = x_2 = 2 \Rightarrow \lambda_1 = 1$

$\therefore [2, 2]^T$ 为KKT点。

一阶最优性条件

一般约束优化

$$\min f(x)$$

$$s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m$$

$$h_j(x) = 0 \quad j = 1, 2, \dots, l$$



$$\min f(x)$$

$$s.t. \quad g(x) \geq 0$$

$$h(x) = 0$$

$$\text{其中 } g(x) = \begin{bmatrix} g_1(x) \\ g_2(x) \\ \vdots \\ g_m(x) \end{bmatrix}, h(x) = \begin{bmatrix} h_1(x) \\ h_2(x) \\ \vdots \\ h_l(x) \end{bmatrix}$$

■ 难点：等式约束可行移动的描述

一阶最优性条件

曲面&曲线： 称点集 $C = \{x = x(t) \mid t_0 \leq t \leq t_1\}$ 为曲面 $S = \{x \mid h(x) = 0\}$ 上的一条曲线，如果对所有 $t \in [t_0, t_1]$ 均有 $h(x(t)) = 0$.
如果导数 $x'(t) = \frac{dx(t)}{dt}$ 存在，则称曲线是可微的. 此时的一阶导数 $x'(t)$ 是曲线在点 $x(t)$ 处的切向量.

切平面： 曲面 S 上在点 x 处所有可微曲线的切向量组成的集合称为曲面 S 在点 x 的切平面, 记为 $T(x)$.

收集了所有可能的切向量（序列可行方向）！

一阶最优性条件

例9 考虑单位球面 $S = \{x \mid h(x) = x_1^2 + x_2^2 + x_3^2 - 1 = 0\}$ 以及

$$\text{单位圆周曲线 } C = \left\{ x = x(t) \mid x(t) = \begin{pmatrix} \sin t \\ \cos t \\ 0 \end{pmatrix}, 0 \leq t \leq 2\pi \right\}.$$

- * 单位圆周曲线 C 为单位球面 S 上的一条曲线，因为对所有 $t \in [0, 2\pi]$ 均有 $h(x(t)) = 0$.
- * 由于 $x'(t) = \frac{dx(t)}{dt} = (\cos t, -\sin t, 0)^T$ ，因此该曲线是可微的.
- * 考虑 S 上的点 $x = (1, 0, 0)^T$ ，其切平面 $T(x) = \{d \in \mathbb{R}^3 \mid d_1 = 0\}$ ，即 $x_2 O x_3$ 平面.
- 注意到在点 $x = (1, 0, 0)^T$ 处， $\nabla h(x) = (2, 0, 0)^T$ ，此时有

$$T(x) = \{d \in \mathbb{R}^3 \mid d_1 = 0\} = \boxed{\{d \in \mathbb{R}^3 \mid \nabla h(x)^T d = 0\}}.$$

线性子空间，且比切平面更易于计算！



一阶最优性条件

线性化可行方向集(锥)

子空间： $H(x) := \{d \mid \nabla h(x)^T d = 0\}$ 其中 $\nabla h(x) = (\nabla h_1(x), \nabla h_2(x), \dots, \nabla h_l(x))$

注意到：□ 记 $L_h(\bar{x}) := \{x \in R^n \mid h(\bar{x}) + \nabla h(\bar{x})^T (x - \bar{x}) = 0\}$ ，它是约束集

$S = \{x \in R^n \mid h(x) = 0\}$ 中的约束函数 h 线性化产生的约束集。

□ $H(\bar{x})$ 为集合 $L_h(\bar{x})$ 的可行方向集(锥)，因而称为约束集 S 在 \bar{x} 处的线性化可行方向集(锥)。

结论：设 \bar{x} 是约束集合 $S = \{x \in R^n \mid h(x) = 0\}$ 上的点， $T(\bar{x})$ 为 S 在 \bar{x} 处的切平面， $H(\bar{x})$ 为相应的线性化可行方向集，则有

$T(\bar{x}) \subseteq H(\bar{x})$ ，即若向量 $d \in T(\bar{x})$ ，则有 $\nabla h(\bar{x})^T d = 0$ 。

问题：包含关系是否可以取等号？何时相等？



一阶最优性条件

线性化可行方向集(锥)

定理7: 设 $\bar{x} \in S = \{x \mid h(x) = 0\}$ 且 $\{\nabla h_1(\bar{x}), \dots, \nabla h_l(\bar{x})\}$ 线性无关,
则 $T(\bar{x}) = H(\bar{x})$.



一阶最优性条件

证明：设 $d \in H(\bar{x})$, 考虑非线性方程组 $h(\bar{x} + td + \nabla h(\bar{x})y) = 0$

其中 $t \in R^1, y \in R^l$. 该方程组有解 $(y, t) = (0, 0)$.

在 $t = 0$ 处, h 关于 y 的 *Jacobi* 矩阵为 $\nabla h(\bar{x})^T \nabla h(\bar{x})$

由隐函数定理, 在 $t = 0$ 的邻域, 存在连续可微函数

$y = y(t) (y(0) = 0)$, 使 $h(\bar{x} + td + \nabla h(\bar{x})y(t)) = 0$ 成立

令 $x(t) = \bar{x} + td + \nabla h(\bar{x})y(t)$, 则 $x(t)$ 为曲面 S 上过 $x(0)$ 的一条曲线。在点 $x(0) = \bar{x}$, 切向量为

$$x'(0) = d + \nabla h(\bar{x})y'(0)$$

又 $\nabla h(\bar{x})^T d + \nabla h(\bar{x})^T \nabla h(\bar{x})y'(0) = 0$

而 $d \in H(\bar{x}) \Rightarrow \nabla h(\bar{x})^T d = 0, \because \{\nabla h_1(\bar{x}), \dots, \nabla h_l(\bar{x})\}$ 线性无关

$\therefore \nabla h(\bar{x})^T \nabla h(\bar{x})$ 可逆, $\Rightarrow y'(0) = 0 \Rightarrow x'(0) = d \Rightarrow d \in T(\bar{x})$.



一阶最优性条件

几何条件

定理8: 设 $\bar{x} \in S$, $f(x)$ 和 $g_i(x)(i \in I)$ 在 \bar{x} 处可微, $g_i(x)(i \notin I)$ 在 \bar{x} 处连续, $h_j(j=1,2,\dots,l)$ 在 \bar{x} 处连续可微, 且 $\{\nabla h_1(\bar{x}), \dots, \nabla h_l(\bar{x})\}$ 线性无关。如果 \bar{x} 是问题(NP)的局部最优解, 则在 \bar{x} 处, 有

$$F_0 \cap G_0 \cap H_0 = \emptyset,$$

其中 $F_0 = \{d \mid \nabla f(\bar{x})^T d < 0\},$

目标函数下降方向

$G_0 = \{d \mid \nabla g_i(\bar{x})^T d > 0, i \in I\},$ 不等式约束局部约束方向

$H_0 = \{d \mid \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l\}.$ 等式约束的切方向

} 可行方向

一阶最优性条件

定理8: 设 $\bar{x} \in S$, $f(x)$ 和 $g_i(x)(i \in I)$ 在 \bar{x} 处可微, $g_i(x)(i \notin I)$ 在 \bar{x} 处连续, $h_j(j=1,2,\dots,l)$ 在 \bar{x} 处连续可微, 且 $\{\nabla h_1(\bar{x}), \dots, \nabla h_l(\bar{x})\}$ 线性无关。如果 \bar{x} 是问题(NP)的局部最优解, 则在 \bar{x} 处, 有

$$F_0 \cap G_0 \cap H_0 = \emptyset,$$

其中

$$F_0 = \{d \mid \nabla f(\bar{x})^T d < 0\},$$

$$G_0 = \{d \mid \nabla g_i(\bar{x})^T d > 0, i \in I\},$$

$$H_0 = \{d \mid \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l\}.$$

$$\begin{cases} Ax < 0 \\ Bx = 0 \end{cases} \text{ 无解}$$

一阶最优性条件

引理1 若系统 $Ax < 0, Bx = 0$ 无解,则系统 $A^T y + B^T z = 0, y \geq 0$,且 $(y; z) \neq 0$ 有解.

证明: 假设系统 $Ax < 0, Bx = 0$ 无解, 定义

$$S_1 = \left\{ \begin{bmatrix} d_1 \\ d_2 \end{bmatrix} \mid d_1 = Ax, d_2 = Bx, x \in R^n \right\}, \quad S_2 = \left\{ \begin{bmatrix} d_1 \\ d_2 \end{bmatrix} \mid d_1 < 0, d_2 = 0 \right\}$$

则 S_1, S_2 为非空凸集, 且 $S_1 \cap S_2 = \emptyset$, 由凸集分离定理

存在非零向量 $p = \begin{pmatrix} y \\ z \end{pmatrix}$, 使得对 $\forall x \in R^n, \begin{bmatrix} d_1 \\ d_2 \end{bmatrix} \in cl S_2$ 有

$$y^T Ax + z^T Bx \geq y^T d_1 + z^T d_2 = y^T d_1$$

令 $x = 0, \because d_1 < 0, \therefore y \geq 0$.

令 $d_1 \rightarrow 0$, 得 $y^T Ax + z^T Bx \geq 0$.

取 $x = -(A^T y + B^T z)$, 则有 $-\|A^T y + B^T z\|^2 \geq 0$

$\Rightarrow A^T y + B^T z = 0$. 由于 $p = \begin{pmatrix} y \\ z \end{pmatrix} \neq 0$, 因此有 $y \neq 0$ 或者 $z \neq 0$. 证毕.

一阶最优性条件

Linear Independency Constraint Qualification(LICQ)

定义: 设 \bar{x} 为可行点, 不等式约束中在 \bar{x} 起作用约束下标集记为 I , 如果向量组

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, 2, \dots, l\}$$

线性无关, 则称约束集 $\{x \mid g(x) \geq 0, h(x) = 0\}$ 在 \bar{x} 处线性无关约束规范 (LICQ) 成立。

此时, 称 \bar{x} 为约束 $g(x) \geq 0$ 和 $h(x) = 0$ 的正则点。



一阶最优性条件

KKT条件

定理11(KKT必要条件) 考虑问题

$$\begin{cases} \min f(x) \\ \text{s.t. } g_i(x) \geq 0, i = 1, \dots, m \\ h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 \bar{x} 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$. $f, g_i (i \in I)$ 在 \bar{x} 处可微,
 $g_i (i \notin I)$ 在 \bar{x} 连续, $h_j (j = 1, \dots, l)$ 在 \bar{x} 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关 (即LICQ成立), 若 \bar{x} 是局部最优解, 则存在数 $w_i, i \in I$
和 $v_j (j = 1, \dots, l)$, 使得

$$\nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0.$$

$$w_i \geq 0 \quad (i \in I).$$



一阶最优性条件

定理12(KKT必要条件) 考虑问题

$$\begin{cases} \min f(x) \\ \text{s.t. } g_i(x) \geq 0, i = 1, \dots, m \\ h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 \bar{x} 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$. f, g_i 在 \bar{x} 处可微, $h_j (j = 1, \dots, l)$ 在 \bar{x} 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关(LICQ), 若 \bar{x} 是局部最优解, 则存在数 $w_i, i \in I$ 和 $v_j (j = 1, \dots, l)$, 使得

$$\nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0$$

$$w_i g_i(\bar{x}) = 0, i = 1, 2, \dots, m$$

$$w_i \geq 0 \quad i = 1, 2, \dots, m.$$



一阶最优性条件

例11 求如下不等式约束优化问题的KKT点:

$$\left\{ \begin{array}{l} \min f = (x_1 - 1)^2 + (x_2 - 1)^2 \\ s.t. \quad -x_1 - x_2 + 2 \geq 0 \\ \quad \quad x_2 - x_1 = 1 \\ \quad \quad x_1 \geq 0 \\ \quad \quad x_2 \geq 0 \end{array} \right.$$

分析: $\nabla f(x) = (2(x_1 - 1), 2(x_2 - 1))^T$ $\nabla g_1(x) = (-1, -1)^T$
 $\nabla g_2(x) = (1, 0)^T$ $\nabla g_3(x) = (0, 1)^T$ $\nabla h(x) = (-1, 1)^T$



一阶最优性条件

KKT条件为:

$$\left\{ \begin{array}{l} 2(x_1 - 1) - w_1(-1) - w_2 - v(-1) = 0 \\ 2(x_2 - 2) - w_1(-1) - w_3 - v = 0 \\ -x_1 - x_2 + 2 \geq 0 \\ x_2 - x_1 = 1 \\ x_1, x_2 \geq 0 \\ w_1(-x_1 - x_2 + 2) = 0 \\ w_2 x_1 = 0 \\ w_3 x_2 = 0 \\ w_1, w_2, w_3 \geq 0 \end{array} \right.$$

$$x^* = \left(\frac{1}{2}, \frac{3}{2} \right)^T \text{ 为 } KKT \text{ 点.}$$

$$w_1 = 1, w_2 = w_3 = v = 0$$

一阶最优性条件

Lagrange函数

定义 约束优化问题 $\min_{x \in \mathbb{R}^n} \{f(x) : g_i(x) \geq 0, i = 1, \dots, m; h_j(x) = 0, j = 1, \dots, l\}$ 的**Lagrange函数**定义为

$$\begin{aligned} L(x, w, v) &= f(x) - \sum_{i=1}^m w_i g_i(x) - \sum_{j=1}^l v_j h_j(x) \\ &= f(x) - w^T g(x) - v^T h(x) \end{aligned}$$

其中 $w = (w_1, w_2, \dots, w_m)^T \in R_+^m$, $v = (v_1, v_2, \dots, v_l)^T \in R^l$

称为Lagrange乘子.

- 可行解 x 处: $f(x) \geq L(x, w, v)$
- 不等式约束的乘子符号由不等号方向决定: $\langle g(x), w \rangle \geq 0$



一阶最优性条件

KKT条件

定理13(KKT必要条件) 考虑问题

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 \bar{x} 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$. f, g_i 在 \bar{x} 处可微, $h_j (j = 1, \dots, l)$ 在 \bar{x} 连续可微, 设LICQ在 \bar{x} 处满足, 若 \bar{x} 是局部最优解, 则存在乘子向量 $\bar{w} \geq 0, \bar{v}$, 使得

$$\nabla_x L(\bar{x}, \bar{w}, \bar{v}) = 0.$$



一阶最优性条件

一阶最优性条件

$$\left\{ \begin{array}{l} \nabla_x L(x, w, v) = 0 \\ w_i g_i(x) = 0, i = 1, 2, \dots, m \\ g_i(x) \geq 0, i = 1, 2, \dots, m \\ h_j(x) = 0, j = 1, 2, \dots, l \\ w_i \geq 0, i = 1, 2, \dots, m \end{array} \right.$$

Lagrange函数梯度为0

互补条件

原始可行性

对偶可行性

(见后续对偶理论部分)



凸优化最优性条件

凸优化模型

$$\min f(x)$$

$$s.t. \quad x \in \Omega := \left\{ x \in R^n \left| \begin{array}{l} g_i(x) \geq 0, i = 1, \dots, m \\ h_j(x) = 0, j = 1, \dots, l \end{array} \right. \right\}$$

若 $f(x)$ 是凸函数, $g_i(x)(i = 1, \dots, m)$ 是凹函数,
 $h_j(x)(j = 1, \dots, l)$ 是线性函数, 则原问题为凸规划.

- $g_i(x)$ 凹函数 $\Rightarrow -g_i(x)$ 凸 $\Rightarrow \{x | -g_i(x) \leq 0\}$ 凸集 (水平集性质)
- $h_j(x)$ 线性函数 $\Rightarrow \{x | -h_j(x) \leq 0\}, \{x | h_j(x) \leq 0\}$ 凸集 $\Rightarrow \{x | h_j(x) = 0\}$ 凸集

基本假设:

- 可行域 Ω 为非空闭凸集
- 凸函数 f 连续可微



凸优化最优性条件

常见凸优化

线性规划

$$\begin{array}{ll}\min & c^T x \\ \text{s.t.} & Ax = b \\ & x \geq 0\end{array}$$

线性最小二乘

$$\min \quad \frac{1}{2} \|Ax - b\|^2$$

Lasso

$$\begin{array}{ll}\min & \frac{1}{2} \|Ax - b\|^2 \\ \text{s.t.} & \|x\|_1 \leq s\end{array}$$

凸二次规划

$$\begin{array}{ll}\min & \frac{1}{2} x^T Q x + g^T x \quad Q \text{ 半正定} \\ \text{s.t.} & a_i^T x = b_i, \quad i \in \mathcal{E} \\ & a_i^T x \geq b_i, \quad i \in I\end{array}$$

凸优化最优性条件

性质1 凸优化问题的任一局部最优解为全局最优解.

证明: 设 x^* 为凸优化局部最优解, 则存在 $\delta > 0$, 对任意 $x \in N(x^*, \delta) \cap \Omega$ 都有 $f(x^*) \leq f(x)$. **反证法.** 假设 x^* 不是全局最优解, 则存在 $\bar{x} \in \Omega$, 使得


$$f(\bar{x}) < f(x^*).$$

考虑线段 $[\bar{x}, x^*]$ 上一点 $y := \lambda \bar{x} + (1 - \lambda)x^*$, $\lambda \in (0, 1)$, 由凸函数定义

$$f(y) \leq \lambda f(\bar{x}) + (1 - \lambda)f(x^*) < \lambda f(x^*) + (1 - \lambda)f(x^*) = f(x^*)$$

当 λ 充分小时, $y \in N(x^*, \delta) \cap \Omega$ 且 $f(y) < f(x^*)$,

这与 x^* 为局部最优解矛盾. 证毕



凸优化最优性条件

性质2 凸优化问题的最优解集为凸集.

证明: 设最优解集为 S , 若 $S = \emptyset$, 结论显然. 若 $S \neq \emptyset$, 设 $x^* \in S$, 最优解集可表示为

$$S := \{x \in \Omega | f(x) \leq f(x^*)\} = \Omega \cap \{x \in \mathbb{R}^n | f(x) \leq f(x^*)\}$$

由于 Ω 为凸集, 凸函数的水平集 $\mathcal{L}(x^*) = \{x \in \mathbb{R}^n | f(x) \leq f(x^*)\}$ 为凸集, 根据两个凸集交集仍为凸集可知

$$S = \Omega \cap \{x \in \mathbb{R}^n | f(x) \leq f(x^*)\}$$

为凸集. 证毕

凸优化最优性条件

性质3 严格凸优化问题若存在最优解，则最优解唯一。


证明： 假设 x^*, y^* 均为严格凸优化的最优解，且 $x^* \neq y^*$ ，取 $z^* = \frac{1}{2}(x^* + y^*)$ ，
则 $z^* \in \Omega$.根据严格凸函数的定义有

$$f(z^*) < \frac{1}{2}f(x^*) + \frac{1}{2}f(y^*) = f(x^*)$$

与 x^* 为最优解矛盾。 证毕



严格凸优化问题不一定存在最优解.



$$\min_{x \in \mathbb{R}} e^{-x}$$

$$(e^{-x})'' = e^{-x} > 0$$

凸优化最优性条件

稳定点： 称 x^* 为约束优化问题 $\min \{f(x): x \in \Omega\}$ 的稳定点,
若满足 $\langle \nabla f(x^*), x - x^* \rangle \geq 0, \forall x \in \Omega$.

性质4 凸优化问题的全局最优解与稳定点等价.

证明： “ \Leftarrow ” 若 x^* 为稳定点,即对任意 $x \in \Omega$, $\langle \nabla f(x^*), x - x^* \rangle \geq 0$.

利用凸函数的性质得

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle \geq f(x^*),$$

因而 x^* 为全局最优解.

凸优化最优性条件

证明：（续）

“ \Rightarrow ” 设 x^* 为凸优化问题的全局最优解，由一阶最优性条件可知，在 x^* 处不存在可行且使得目标函数下降的方向。注意到，由 Ω 的凸性可知 $\forall x \in \Omega, \forall \lambda \in (0, 1)$,

$$x^* + \lambda(x - x^*) = \lambda x + (1 - \lambda)x^* \in \Omega$$

因此， $x - x^*$ 是 x^* 处的可行方向。从而 $\langle \nabla f(x^*), x - x^* \rangle \geq 0, \forall x \in \Omega$ ，即 x^* 为稳定点。

证毕

当可行域
为凸集时，
则最优解
为稳定点。

凸优化最优性条件

定理1 若约束优化问题的可行域 Ω 为非空闭凸集，则其任一局部最优解 x^* 均为稳定点，即 $\langle \nabla f(x^*), x - x^* \rangle \geq 0, \forall x \in \Omega$.

注意： 上述定理与目标函数是否为凸函数无关，但可行域的凸性不能去掉！




图1




图2

若 Ω 非凸，上述结论可能不成立.

如图2所示, x^* 是局部最优解，但 x^* 不是稳定点，因为 $\langle \nabla f(x^*), \bar{x} - x^* \rangle < 0$.



凸优化最优性条件

鞍点

定义1 称 $(x^*, \lambda^*, \mu^*) \in \mathbb{R}^n \times \mathbb{R}^{|\mathcal{E}|} \times \mathbb{R}_+^{|\mathcal{I}|}$ 为约束优化问题

$$\min_x \{f(x) : h_i(x) = 0, i \in \mathcal{E}; g_i(x) \geq 0, i \in \mathcal{I}\}$$

的Lagrange函数 $L(x, \lambda, \mu)$ 的鞍点, 若 $\forall (x, \lambda, \mu) \in \mathbb{R}^n \times \mathbb{R}^{|\mathcal{E}|} \times \mathbb{R}_+^{|\mathcal{I}|}$ 有

$$L(x^*, \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*).$$



$$x^* \in \operatorname{argmin}_{x \in \mathbb{R}^n} L(x, \lambda^*, \mu^*) \quad \& \quad (\lambda^*, \mu^*) \in \operatorname{argmax}_{\substack{\lambda \in \mathbb{R}^{|\mathcal{E}|} \\ \mu \in \mathbb{R}_+^{|\mathcal{I}|}}} L(x^*, \lambda, \mu)$$

凸优化最优性条件

定理2 若 (x^*, λ^*, μ^*) 是凸优化的KKT点对, 则 (x^*, λ^*, μ^*) 为Lagrange函数的鞍点.

证明: ■ 先证 $x^* \in \operatorname{argmin}_{x \in \mathbb{R}^n} L(x, \lambda^*, \mu^*)$

由 $L(x, \lambda^*, \mu^*) = f(x) - \sum_{i \in \mathcal{E}} \lambda_i^* h_i(x) - \sum_{i \in I} \mu_i^* g_i(x)$ 关于 $x \in \mathbb{R}^n$ 为凸函数

$$L(x, \lambda^*, \mu^*) \geq L(x^*, \lambda^*, \mu^*) + (x - x^*)^T \nabla_x L(x^*, \lambda^*, \mu^*) = L(x^*, \lambda^*, \mu^*)$$

■ 再证 $(\lambda^*, \mu^*) \in \operatorname{argmax}_{\substack{\lambda \in \mathbb{R}^{|\mathcal{E}|} \\ \mu \in \mathbb{R}_+^{|I|}}} L(x^*, \lambda, \mu)$ **=0** (x^*, λ^*, μ^*) 为KKT点对

$$\begin{aligned} L(x^*, \lambda, \mu) - L(x^*, \lambda^*, \mu^*) &= - \sum_{i \in \mathcal{E}} \lambda_i h_i(x^*) - \sum_{i \in I} \mu_i g_i(x^*) + \sum_{i \in \mathcal{E}} \lambda_i^* h_i(x^*) + \sum_{i \in I} \mu_i^* g_i(x^*) \\ &= - \sum_{i \in I} \mu_i g_i(x^*) \leq 0 \quad \text{对任意 } \lambda \in \mathbb{R}^{|\mathcal{E}|}, \mu \in \mathbb{R}_+^{|I|} \end{aligned}$$

凸优化最优性条件

定理3 若 (x^*, λ^*, μ^*) 是优化问题Lagrange函数的鞍点, 则 (x^*, λ^*, μ^*) 为KKT点对.

证明: ■ 由 $x^* \in \operatorname{argmin}_{x \in \mathbb{R}^n} L(x, \lambda^*, \mu^*) \Rightarrow \nabla_x L(x^*, \lambda^*, \mu^*) = \mathbf{0}$

■ 由 $(\lambda^*, \mu^*) \in \operatorname{argmax}_{\substack{\lambda \in \mathbb{R}^{|\mathcal{E}|} \\ \mu \in \mathbb{R}_+^{|\mathcal{I}|}}} L(x^*, \lambda, \mu) = f(x^*) - \sum_{i \in \mathcal{E}} \lambda_i h_i(x^*) - \sum_{i \in \mathcal{I}} \mu_i g_i(x^*)$




$$\begin{aligned} h_i(x^*) &= 0, & i \in \mathcal{E}; \\ g_i(x^*) &\geq 0, \mu_i^* \geq 0, \mu_i^* g_i(x^*) = 0, & i \in \mathcal{I}, \end{aligned}$$

因此, (x^*, λ^*, μ^*) 为KKT点对

注意: 该定理无需问题为凸优化!

凸优化最优性条件



***Slater 条件:** 若存在可行点 \bar{x} 使得 $g_i(\bar{x}) > 0, \forall i$

任意可行解处
均有可行方向

则称该问题满足Slater约束规格或Slater条件.

- 对凸优化 $\min_x \{f(x) : Ax = b\}$, 其中 f 为适当闭凸函数, 若存在 $\bar{x} \in \text{int dom} f$, 使得 $A\bar{x} = b$, 则称Slater条件成立.



对偶规划与对偶理论

- Lagrange对偶问题
- 弱对偶理论
- 鞍点与强对偶定理
- Lagrange乘子的经济学解释

对偶规划与对偶理论

原始优化问题

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, i = 1, \dots, m \\ & h_j(x) = 0, j = 1, \dots, l \\ & x \in D \end{aligned} \quad (\text{P})$$

容易处理的集合约束

Lagrange对偶问题

$$\begin{aligned} \max \quad & \theta(w, v) \\ \text{s.t.} \quad & w \geq 0 \end{aligned} \quad (\text{D})$$

其中 $\theta(w, v) = \inf \left\{ f(x) - \sum_{i=1}^m w_i g_i(x) - \sum_{j=1}^l v_j h_j(x) \mid x \in D \right\}$

$$L(x; w, v)$$

Lagrange函数

对偶规划与对偶理论

对偶问题必为凸规划

$$\begin{aligned} \text{(D)} \quad & \max \theta(w, v) \\ & s.t. \quad w \geq 0 \end{aligned}$$

✓ 可行域为凸集合

✓ 目标函数为凹函数

对于任意的 $x \in D$, *Lagrange* 函数 $L(x; w, v)$ 是 w, v 的线性函数, 对偶函数 $\theta(w, v)$ 作为线性函数的逐点下确界, 必然是一个凹函数

对偶规划与对偶理论

例1 求如下优化问题的Lagrange对偶问题

$$\begin{aligned} \min \quad & x_1^2 + x_2^2 \\ \text{s. t.} \quad & x_1 + x_2 - 4 \geq 0 \\ & x_1, x_2 \geq 0 \end{aligned}$$

解. 将容易处理的非负约束看成集合约束, 即

$$x \in D := \{x = (x_1, x_2)^T : x_1, x_2 \geq 0\}$$

则Lagrange对偶问题的目标函数为:

$$\theta(w) := \inf_{x \in D} \{x_1^2 + x_2^2 - w(x_1 + x_2 - 4)\}, w \geq 0$$

对偶规划与对偶理论

$$\begin{aligned}\theta(w) &= \inf \{x_1^2 + x_2^2 - w(x_1 + x_2 - 4) \mid x \in D\} \\ &= \inf \{x_1^2 - wx_1 + x_2^2 - wx_2 + 4w \mid x_1 \geq 0, x_2 \geq 0\} \\ &= \inf \{x_1^2 - wx_1 \mid x_1 \geq 0\} + \inf \{x_2^2 - wx_2 \mid x_2 \geq 0\} + 4w\end{aligned}$$

当 $w \geq 0$ 时,

$$\inf \{x_1^2 - wx_1 \mid x_1 \geq 0\} = \left(\frac{w}{2}\right)^2 - w \times \frac{w}{2} = -\frac{w^2}{4}.$$

$$\inf \{x_2^2 - wx_2 \mid x_2 \geq 0\} = \left(\frac{w}{2}\right)^2 - w \times \frac{w}{2} = -\frac{w^2}{4}.$$

$$\therefore \theta(w) = -\frac{w^2}{4} - \frac{w^2}{4} + 4w = -\frac{w^2}{2} + 4w.$$

对偶问题



$$\begin{aligned}\max & -\frac{w^2}{2} + 4w \\ \text{s.t.} & w \geq 0\end{aligned} \quad (\text{D})$$

对偶规划与对偶理论

习题1 求如下优化问题的Lagrange对偶问题

$$\max b^T x$$

$$\text{s. t. } x^T Q x \leq 1$$

其中 $b \in \mathbb{R}^n \setminus \{0\}$, $Q \in \mathbb{R}^{n \times n}$ 为对称正定矩阵.


答案. 该问题的Lagrange对偶问题为:

$$\min \frac{b^T Q^{-1} b}{4w} + w$$

$$\text{s. t. } w > 0$$

对偶规划与对偶理论

对偶是一种普遍现象,辩证统一



对偶规划与对偶理论

弱对偶定理

定理 设 x 和 (w, v) 分别是原问题和对偶问题的可行解, 则

$$f(x) \geq \theta(w, v).$$

证明: $\because x$ 和 (w, v) 是可行解,

$$\therefore g(x) \geq 0, h(x) = 0, w \geq 0$$

$$\therefore \theta(w, v) = \inf_{x'} \{f(x') - w^T g(x') - v^T h(x') \mid x' \in D\}$$

$$\leq f(x) - w^T g(x) - v^T h(x)$$

$$\leq f(x).$$



对偶规划与对偶理论

$$(P) \quad \frac{\inf_{x \in D} \sup_{w \geq 0} L(x; w, v)}{p^*}$$

$$(D) \quad \frac{\sup_{w \geq 0} \inf_{x \in D} L(x; w, v)}{d^*}$$

□ 对偶间隙(Duality Gap): $\delta = p^* - d^* \geq 0$

□ 问题: 对偶间隙 δ 何时为0呢?

对偶规划与对偶理论

回顾：鞍点

定义 称 $(x^*, \lambda^*, \mu^*) \in \mathbb{R}^n \times \mathbb{R}^{|\mathcal{E}|} \times \mathbb{R}_+^{|\mathcal{I}|}$ 为约束优化问题

$$\min_x \{f(x) : h_i(x) = 0, i \in \mathcal{E}; g_i(x) \geq 0, i \in \mathcal{I}\}$$

的Lagrange函数 $L(x, \lambda, \mu)$ 的鞍点, 若 $\forall (x, \lambda, \mu) \in \mathbb{R}^n \times \mathbb{R}^{|\mathcal{E}|} \times \mathbb{R}_+^{|\mathcal{I}|}$ 有

$$L(x^*, \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*).$$



$$x^* \in \operatorname{argmin}_{x \in \mathbb{R}^n} L(x, \lambda^*, \mu^*) \quad \& \quad (\lambda^*, \mu^*) \in \operatorname{argmax}_{\substack{\lambda \in \mathbb{R}^{|\mathcal{E}|} \\ \mu \in \mathbb{R}_+^{|\mathcal{I}|}}} L(x^*, \lambda, \mu)$$

对偶规划与对偶理论

强对偶定理

定理 设 (x^*, w^*, v^*) 为优化问题(P)的Lagrange函数的鞍点, 则 x^* 与 (w^*, v^*) 分别是原问题与对偶问题的最优解且对偶间隙为零.

证明: $(w^*, v^*) \in \underset{\substack{v \in \mathbb{R}^{|\mathcal{E}|} \\ w \in \mathbb{R}_+^{|\mathcal{I}|}}}{\operatorname{argmax}} L(x^*, w, v) \Rightarrow \begin{aligned} &h_i(x^*) = 0, i \in \mathcal{E}; \\ &w_i^* \geq 0, g_i(x^*) \geq 0, w_i^* g_i(x^*) = 0, i \in \mathcal{I} \end{aligned}$



$x^* \in \underset{x \in \mathbb{R}^n}{\operatorname{argmin}} L(x, w^*, v^*) \Rightarrow \begin{aligned} &\text{对(P)的任一可行解 } x, \\ &f(x) \geq L(x, w^*, v^*) \geq L(x^*, w^*, v^*) = f(x^*) \end{aligned}$

最优解 x^*



对偶理论

强对偶定理

定理 设 (x^*, w^*, v^*) 为优化问题(P)的Lagrange函数的鞍点, 则 x^* 与 (w^*, v^*) 分别是原问题与对偶问题的最优解且对偶间隙为零.

证明: (续) $x^* \in \operatorname{argmin}_{x \in \mathbb{R}^n} L(x, w^*, v^*) \Leftrightarrow \theta(w^*, v^*) = L(x^*, w^*, v^*)$

已证 $L(x^*, w^*, v^*)$ 为问题(P)的最优值 $f(x^*)$, 由弱对偶定理可知:

对(D)的任一可行解 (w, v) , 有 $\theta(w, v) \leq L(x^*, w^*, v^*) = \theta(w^*, v^*)$

则(D)的最优解为 (w^*, v^*) , 且 $f(x^*) = \theta(w^*, v^*)$.

最优解 (w^*, v^*)

对偶规划与对偶理论

乘子的经济学解释

$$\begin{aligned} & \min f(x) \\ \text{(NP)} \quad & s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ & \quad \quad h_j(x) = 0, j = 1, \dots, l \end{aligned}$$

↓ 线性扰动

$$\begin{aligned} & \min f(x) \\ s.t. \quad & g_i(x) \geq \varepsilon_i, i = 1, \dots, m \\ & \quad \quad h_j(x) = \lambda_j, j = 1, \dots, l \\ & \varepsilon = (\varepsilon_1, \dots, \varepsilon_m)^T \quad \lambda = (\lambda_1, \dots, \lambda_l)^T \end{aligned}$$

- 设 x^* 为局部最优解;
 (w^*, v^*) 为相应的Lagrange乘子

$$\begin{aligned} x^*(0, 0) &= x^* \\ (w^*(0), v^*(0)) &= (w^*, v^*) \end{aligned}$$

- 设 $x^*(\varepsilon, \lambda)$ 为扰动问题的局部最优解;
 $(w^*(\varepsilon), v^*(\lambda))$ 为相应的Lagrange乘子



对偶规划与对偶理论

乘子的经济学解释

定理：设函数 f, g_i, h_j 二阶连续可微， x^* 是(NP)问题的局部最优解， (w^*, v^*) 是相应的Lagrange乘子向量，设 $x^*(\varepsilon, \lambda)$ 是扰动问题的局部最优解， $(w^*(\varepsilon), v^*(\lambda))$ 是相应的Lagrange乘子向量，则有：


$$\nabla_{\varepsilon} f(x^*(\varepsilon, \lambda))|_{\varepsilon=0} = w^*, \nabla_{\lambda} f(x^*(\varepsilon, \lambda))|_{\lambda=0} = v^*.$$

对偶规划与对偶理论

例： 某企业预算以2千元作为广告费, 根据以往的经验, 若以 x_1 千元作广播广告, x_2 千元作报纸广告, 则销售金额为 $-2x_1^2 - 10x_2^2 - 8x_1x_2 + 18x_1 + 34x_2$ (千元)
试问: (1) 如何分配2千元的广告费? (2) 广告费预算作微小改变后的影响如何?

解： $\min f(x) = 2x_1^2 + 10x_2^2 + 8x_1x_2 - 18x_1 - 34x_2$
s.t. $x_1 + x_2 - 2 = 0$
 $x_1 \geq 0, x_2 \geq 0$

KKT条件为: $4x_1 + 8x_2 - 18 - w_1 - v = 0$
 $20x_2 + 8x_1 - 34 - w_2 - v = 0$
 $x_1w_1 = 0, x_2w_2 = 0,$
 $x_1 + x_2 - 2 = 0$
 $x_1 \geq 0, x_2 \geq 0$
 $w_1 \geq 0, w_2 \geq 0$



$$\begin{aligned} x^* &= (1, 1)^T \\ w^* &= (0, 0)^T \\ v^* &= -6 \end{aligned}$$

对偶规划与对偶理论

若广告费作微小改动，则相应的扰动问题为

$$\begin{aligned} \min f(x) &= 2x_1^2 + 10x_2^2 + 8x_1x_2 - 18x_1 - 34x_2 \\ \text{s.t. } x_1 + x_2 - 2 &= e \\ x_1 \geq 0, x_2 &\geq 0 \end{aligned}$$

$$\text{则有 } \frac{df(x^*(e))}{de} \Big|_{e=0} = v^* = -6$$

KKT点

$$\begin{aligned} x^*(e) &= \left(1 + \frac{3}{2}e, 1 - \frac{e}{2}\right)^T \\ w^*(e) &= (0, 0)^T \\ v^*(e) &= 2e - 6 \\ f(x^*(e)) &= e^2 - 6e - 32 \end{aligned}$$

经济学含义：当 e 增加时， $-f(x^*(e))$ 上升，即当广告费增加后，销售也随着增加，而且销售金额的增加大约为广告费增量的6倍，可见适当增加广告费的预算是有利的。



对偶规划与对偶理论

乘子的经济学解释: 影子价格

- 若把原问题约束条件看成是广义的资源约束, 则右端项的值表示每种资源的可用量.
- 对偶解的经济含义: 资源的单位改变量引起目标函数值的增加量.
- 通常称对偶解为**影子价格**.
- 影子价格的大小客观地反映了资源在系统内的稀缺程度. 资源的影子价格越高, 说明资源在系统内越稀缺, 而增加该资源的供应量对系统目标函数值贡献越大.

影子价格的作用

- (1) 告诉管理者增加何种资源对企业更有利
- (2) 告诉管理者花多大代价购买进资源或卖出资源是合适的
- (3) 为新产品定价提供依据