



Lecture 8: ALM与ADMM


1. 增广拉格朗日算法 (ALM)
2. 交替方向乘子法(ADMM)

等式约束优化的乘子罚

■ 乘子罚函数【Hestenes, Powell, 1969】

$$\min f(x) \quad (1)$$

$$\text{s. t. } c_i(x) = 0, i \in \mathcal{E}$$



$$\min f(x) + \sum y_i c_i(x)$$

$$\text{s. t. } c_i(x) = 0, i \in \mathcal{E}$$



平方惩罚

$$L_\rho(x, y) := f(x) - \sum y_i c_i(x) + \frac{\rho}{2} \sum c_i^2(x)$$

称函数 $L_\rho(x, y)$ 为优化问题的乘子罚函数，也称为增广Lagrange函数。

定理1 对优化问题(1), 设 \mathbf{x}^* 是局部最优解且**二阶充分最优性条件**

$$d^T \nabla_{xx}^2 L(\mathbf{x}^*, \mathbf{y}^*) d > 0, \quad \forall d \in \{d \neq 0: \nabla c_i(\mathbf{x}^*)^T d = 0, i \in \mathcal{E}\}$$

成立, 其中 \mathbf{y}^* 是相应最优Lagrange乘子, 设**向量组** $\{\nabla c_i(\mathbf{x}^*), i \in \mathcal{E}\}$ **线性无关 (LICQ)**, 则存在**有限常数** $\rho^* > 0$, 使得对 **$\forall \rho \geq \rho^*$** , \mathbf{x}^* 是 $\min_x L_\rho(\mathbf{x}, \mathbf{y}^*)$ 的严格局部最优解; 特别地, 若目标函数 f 为凸函数, 所有约束函数为线性的, 则对任意 $\rho > 0$, **问题(1)的最优解都是罚问题** $\min_x L_\rho(\mathbf{x}, \mathbf{y}^*)$ **的最优解**. 另一方面若 \mathbf{x}^* 是 $\min_x L_\rho(\mathbf{x}, \mathbf{y}^*)$ 的局部最优解且 $c_i(\mathbf{x}^*) = 0, i \in \mathcal{E}$, 则 \mathbf{x}^* 是(1)的局部最优解.

补充：二阶最优性条件

二阶最优性条件

约束优化模型

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, \quad i = 1, 2, \dots, m \quad \text{--- 不等式约束} \\ & h_j(x) = 0, \quad j = 1, 2, \dots, l \quad \text{--- 等式约束} \\ & x \in R^n \end{aligned}$$

可行域(集):
$$S = \left\{ x \in R^n \left| \begin{array}{ll} g_i(x) \geq 0, & i = 1, 2, \dots, m \\ h_j(x) = 0, & j = 1, 2, \dots, l \end{array} \right. \right\}$$

二阶最优性条件

KKT条件的非充分性

例1 $\min f(x) = x_2$
 $s.t. \quad g(x) = x_1^2 + x_2 \geq 0$ 求**KKT**点，并说明是否为局部最优解。

解： **KKT**点应满足方程组

$$\begin{cases} \begin{pmatrix} 0 \\ 1 \end{pmatrix} - w \begin{pmatrix} 2x_1 \\ 1 \end{pmatrix} = 0 \\ w(x_1^2 + x_2) = 0 \\ x_1^2 + x_2 \geq 0 \\ w \geq 0 \end{cases} \quad \Rightarrow \quad \begin{aligned} w &= 1 \\ x_1 &= x_2 = 0 \end{aligned}$$

$\bar{x} = (0, 0)^T$ 是KKT点，但不是局部最优解.

二阶最优性条件

定理14（二阶必要条件）：设 $f, g_i (i=1, \dots, m)$ 和 $h_j (j=1, \dots, l)$ 是二次连续可微函数， \bar{x} 为一个局部最优解且在 \bar{x} 处LICQ成立，令 \bar{w}, \bar{v} 为Lagrange乘子，则

$$\underline{d^T \nabla_x^2 L(\bar{x}, \bar{w}, \bar{v}) d \geq 0, \forall d \in \mathbf{C}(\bar{x}, \bar{w}, \bar{v})} := \left\{ d \in R^n \left| \begin{array}{l} \nabla g_i(\bar{x})^T d = 0, i \in I \text{ 且 } \bar{w}_i > 0 \\ \nabla g_i(\bar{x})^T d \geq 0, i \in I \text{ 且 } \bar{w}_i = 0 \\ \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l \end{array} \right. \right\}.$$

$\nabla_x^2 L(\bar{x}, \bar{w}, \bar{v})$ 在临界锥上是半正定的

■ 临界锥（Critical Cone）： $\mathbf{C}(\bar{x}, \bar{w}, \bar{v})$

$\forall d \in \mathbf{C}(\bar{x}, \bar{w}, \bar{v})$, 有 $\bar{w}_i \nabla g_i(\bar{x})^T d = 0, \bar{v}_j \nabla h_j(\bar{x})^T d = 0, \forall i, j$ \bar{x} 是局部最优解且LICQ成立

$0 = \nabla_x L(\bar{x}, \bar{w}, \bar{v}) = \nabla f(\bar{x}) - \sum_{i=1}^m \bar{w}_i \nabla g_i(\bar{x}) - \sum_{j=1}^l \bar{v}_j \nabla h_j(\bar{x})$

$(\bar{x}, \bar{w}, \bar{v})$ 是KKT系统的解

$$d^T \nabla f(\bar{x}) = \sum_{i=1}^m \bar{w}_i d^T \nabla g_i(\bar{x}) + \sum_{j=1}^l \bar{v}_j d^T \nabla h_j(\bar{x}) = 0$$

目标函数值非增非减，临界状态

二阶最优性条件

例2 $\min x_1$

$s.t. \quad x_2 \geq 0$

$$1 - (x_1 - 1)^2 - x_2^2 \geq 0$$

解：该问题的最优解为 $\bar{x} = (0, 0)^T$ ，积极约束集为 $I = \{1, 2\}$ 。

* Lagrange函数为： $L(x, w) = x_1 - w_1 x_2 - w_2 (1 - (x_1 - 1)^2 - x_2^2)$ ，其中 w_1 与 w_2 非负

* 由KKT条件 $\nabla L(\bar{x}, \bar{w}) = 0$ ，可知 $\begin{cases} 1 - 2\bar{w}_2 = 0 \\ -\bar{w}_1 = 0 \end{cases}$ ，从而 $\bar{w} = (0, 1/2)^T$ 。

* 在 \bar{x} 处LICQ成立： 因为 $\nabla g_1(\bar{x}) = (0, 1)^T$ ， $\nabla g_2(\bar{x}) = (2, 0)^T$ 线性无关

* 临界锥为： $C(\bar{x}, \bar{w}) = \{(0, d_2)^T \mid d_2 \geq 0\}$

* 二阶必要性条件在 \bar{x} 处成立： 因为 $\nabla_x^2 L(\bar{x}, \bar{w}) = \begin{bmatrix} 2\bar{w}_2 & 0 \\ 0 & 2\bar{w}_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 正定

二阶最优性条件

二阶充分条件

定理15 若优化问题目标函数与约束函数均二阶连续可微, 设 $(\bar{\mathbf{x}}, \bar{\mathbf{w}}, \bar{\mathbf{v}})$ 是KKT点对且满足如下二阶条件

$$d^T \nabla_{xx}^2 L(\bar{\mathbf{x}}, \bar{\mathbf{w}}, \bar{\mathbf{v}}) d > 0, \quad \forall d \in C(\bar{\mathbf{x}}, \bar{\mathbf{w}}, \bar{\mathbf{v}}) \setminus \{0\},$$

则 $\bar{\mathbf{x}}$ 是约束优化问题的严格局部最优解.

✓ 用于判断**KKT**点是否为局部最优解!

二阶最优性条件

证明： 假设 \bar{x} 不是问题的严格局部极小点, 则存在序列 $\{x^{(k)}\} \subset S$

使得 $x^{(k)} \neq \bar{x}, x^{(k)} \rightarrow \bar{x}$ 且 $f(x^{(k)}) \leq f(\bar{x})$, 即

$$f(x^{(k)}) - f(\bar{x}) = \nabla f(\bar{x})^T (x^{(k)} - \bar{x}) + o(\|x^{(k)} - \bar{x}\|) \leq 0.$$

记 $d^{(k)} = \frac{x^{(k)} - \bar{x}}{\|x^{(k)} - \bar{x}\|}$, 显然, $\forall k \geq 1, \|d^{(k)}\| \equiv 1$.

根据有界序列的性质可知, 存在一个收敛子列 $\{d^{(k_i)}\} \rightarrow d \neq 0$

不妨假设 $d^{(k)} \rightarrow d$

因为 $\nabla f(\bar{x})^T d^k + o(1) \leq 0$ 令 $k \rightarrow \infty$ 于是有 $d^T \nabla f(\bar{x}) \leq 0$

二阶最优性条件

以下证明 $\nabla f(\bar{x})^T d = 0$

将 $g_i(x)$ 在点 \bar{x} 展开, 再令 $x = x^{(k)}$, 得到

$$g_i(x^{(k)}) = g_i(\bar{x}) + \nabla g_i(\bar{x})^T (x^{(k)} - \bar{x}) + o(\|x^{(k)} - \bar{x}\|)$$

$$\Rightarrow \nabla g_i(\bar{x})^T (x^{(k)} - \bar{x}) + o(\|x^{(k)} - \bar{x}\|) \geq 0 \quad (i \in I) \quad \text{取极限}$$

$$\Rightarrow \nabla g_i(\bar{x})^T d \geq 0 \quad (i \in I)$$

同理可证 $\nabla h_j(\bar{x})^T d = 0, \quad j = 1, 2, \dots, l$

利用KKT条件, 得到 $\nabla f(\bar{x})^T d = \sum_{i \in I} \bar{w}_i \nabla g_i(\bar{x})^T d + \sum_{j=1}^l \bar{v}_j \nabla h_j(\bar{x})^T d \geq 0,$

因此, $\nabla f(\bar{x})^T d = 0.$

$$\text{由于 } \nabla f(\bar{x})^T d = \sum_{i \in I} \bar{w}_i \nabla g_i(\bar{x})^T d = 0$$

$$\therefore \nabla g_i(\bar{x})^T d = 0, \quad \text{若 } i \in I \text{ 且 } \bar{w}_i > 0 \quad \Rightarrow \quad d \in \mathbf{C}(\bar{x}, \bar{w}, \bar{v})$$



二阶最优性条件

$\because x^{(k)} \in S$ 由Taylor展开公式, 有

$$\begin{aligned} L(\bar{x}, \bar{w}, \bar{v}) &= f(\bar{x}) \geq f(x^{(k)}) \\ &\geq f(x^{(k)}) - \sum_{i \in I} \bar{w}_i g_i(x^{(k)})^T - \sum_{j=1}^l \bar{v}_j h_j(x^{(k)})^T = L(x^{(k)}, \bar{w}, \bar{v}) \end{aligned}$$

$$\begin{aligned} \text{而 } L(x^{(k)}, \bar{w}, \bar{v}) &= L(\bar{x}, \bar{w}, \bar{v}) + \underbrace{\nabla_x L(\bar{x}, \bar{w}, \bar{v})^T}_{\text{red underline}} (x^{(k)} - \bar{x}) \quad \quad \quad \equiv \mathbf{0} \\ &+ \frac{1}{2} (x^{(k)} - \bar{x})^T \nabla_x^2 L(\bar{x}, \bar{w}, \bar{v}) (x^{(k)} - \bar{x}) + o(\|x^{(k)} - \bar{x}\|^2). \end{aligned}$$

$$\therefore \frac{1}{2} (x^{(k)} - \bar{x})^T \nabla_x^2 L(\bar{x}, \bar{w}, \bar{v}) (x^{(k)} - \bar{x}) + o(\|x^{(k)} - \bar{x}\|^2) \leq 0.$$

$$\therefore d^T \nabla_x^2 L(\bar{x}, \bar{w}, \bar{v}) d \leq 0. \quad \text{矛盾。}$$

二阶最优性条件

例3 $\min f(x) = x_1 x_2$
 $s.t. \quad c(x) = x_1^2 + x_2^2 - 1 = 0$

解：该问题的Lagrange函数为 $L(x, v) = x_1 x_2 - v(x_1^2 + x_2^2 - 1)$ 。

$$\text{由一阶必要条件} \begin{cases} x_2 - 2vx_1 = 0 \\ x_1 - 2vx_2 = 0 \\ x_1^2 + x_2^2 - 1 = 0 \end{cases}$$

可知

$$v^* = \frac{1}{2}, \quad x^* = \left(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2} \right)^T \text{ or } x^* = \left(-\frac{\sqrt{2}}{2}, -\frac{\sqrt{2}}{2} \right)^T$$

或

$$v^* = -\frac{1}{2}, \quad x^* = \left(-\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2} \right)^T \text{ or } x^* = \left(\frac{\sqrt{2}}{2}, -\frac{\sqrt{2}}{2} \right)^T$$

当 $v^* = \frac{1}{2}$ 时，对任意 $d \neq 0$ 满足 $d_1 = -d_2$ ，有

$$d^T \nabla_x^2 L(x^*, v^*) d = -4d_1^2 < 0$$

由二阶充分条件可知， $\left(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2} \right)^T$ 与 $\left(-\frac{\sqrt{2}}{2}, -\frac{\sqrt{2}}{2} \right)^T$ 是

局部极大值点；

当 $v^* = -\frac{1}{2}$ 时，对任意 $d \neq 0$ 满足 $d_1 = d_2$ ，有

$$d^T \nabla_x^2 L(x^*, v^*) d = 4d_1^2 > 0$$

由二阶充分条件可知， $\left(-\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2} \right)^T$ 与 $\left(\frac{\sqrt{2}}{2}, -\frac{\sqrt{2}}{2} \right)^T$ 是

局部最优解。

二阶最优性条件

无约束优化二阶最优性条件

定理16 若 $\bar{x} \in \operatorname{argmin}_x f(x)$, 则 $\nabla f(\bar{x}) = 0, \nabla^2 f(\bar{x}) \succcurlyeq 0$;
若 $\nabla f(\bar{x}) = 0, \nabla^2 f(\bar{x}) \succ 0$, 则 \bar{x} 是严格局部最优解.

定理1 对优化问题(1), 设 \mathbf{x}^* 是局部最优解且二阶充分最优性条件

$$d^T \nabla_{xx}^2 L(\mathbf{x}^*, \mathbf{y}^*) d > 0, \quad \forall d \in \{d \neq 0: \nabla c_i(\mathbf{x}^*)^T d = 0, i \in \mathcal{E}\}$$

成立, 其中 \mathbf{y}^* 是相应最优Lagrange乘子, 设向量组 $\{\nabla c_i(\mathbf{x}^*), i \in \mathcal{E}\}$ 线性无关(LICQ), 则存在**有限常数** $\rho^* > 0$, 使得对 $\forall \rho \geq \rho^*$, \mathbf{x}^* 是 $\min_x L_\rho(\mathbf{x}, \mathbf{y}^*)$ 的严格局部最优解; 特别地, 若目标函数 f 为凸函数, 所有约束函数为线性的, 则对任意 $\rho > 0$, 问题(1)的最优解都是罚问题 $\min_x L_\rho(\mathbf{x}, \mathbf{y}^*)$ 的最优解. 另一方面若 \mathbf{x}^* 是 $\min_x L_\rho(\mathbf{x}, \mathbf{y}^*)$ 的局部最优解且 $c_i(\mathbf{x}^*) = 0, i \in \mathcal{E}$, 则 \mathbf{x}^* 是(1)的局部最优解.

证明

ALM的更新准则

$$x^{k+1} \in \operatorname{argmin}_x L_{\rho_k}(x, y^k)$$

【一阶条件】

$$\nabla L_{\rho_k}(x^{k+1}, y^k) = \nabla f(x^{k+1}) - \sum_{i \in \mathcal{E}} [y_i^k - \rho_k c_i(x^{k+1})] \nabla c_i(x^{k+1}) = 0$$

乘子校正公式

$$y_i^{k+1} = y_i^k - \rho_k c_i(x^{k+1})$$

$$\nabla f(x^*) - \sum_{i \in \mathcal{E}} y_i^* \nabla c_i(x^*) = 0 \quad \text{【KKT条件】}$$

Q: 可行性?

ALM的更新准则

算法停机准则: $\|c(x^{k+1})\|_{\infty} \leq \epsilon$

乘子校正公式

$$y_i^{k+1} = y_i^k - \rho_k c_i(x^{k+1})$$



$$c_i(x^{k+1}) \approx -(y^* - y^k)/\rho_k$$



要使得 $c_i(x^{k+1}) \rightarrow 0$, 可以让乘子 $y^k \rightarrow y^*$, 也可以让罚因子不断增加, 不一定需要 $\rho_k \rightarrow +\infty$.

ALM (乘子罚函数法)

迭代
框架

步1 取 $\rho_0 > 0, y_0 = 0, \gamma > 1$, 取初始点 $x_0, \epsilon > 0, k = 1$

步2 以 x^{k-1} 为初始点求罚函数 $L_{\rho_{k-1}}(x, y^{k-1})$ 的极小值点 x^k

步3 若 $\|c(x^k)\|_\infty \leq \epsilon$, 算法终止, 否则转到下一步

步4 若 $\|c(x^k)\|_\infty \geq \|c(x^{k-1})\|_\infty$, 令 $\rho_k = \gamma \rho_{k-1}, y^k = y^{k-1}$, 令 $k = k + 1$
转步2

步5 若 $\rho_k > \rho_{k-1}$, 或 $\|c(x^k)\|_\infty \leq \frac{1}{4} \|c(x^{k-1})\|_\infty$, 令 $\rho_k = \rho_{k-1}$, 更新
Lagrange乘子 $y_i^{k+1} = y_i^k - \rho_k c_i(x^k), i \in \mathcal{E}$, 令 $k = k + 1$, 转步2;
否则令 $\rho_k = \gamma \rho_{k-1}, y^k = y^{k-1}$, 令 $k = k + 1$

复合优化问题:

$$\min_x g(x) + h(y) \quad \text{s.t.} \quad Ax - y = 0 \quad (\text{P})$$

其中, g, h 为适当闭凸函数, $A \in \mathbb{R}^{m \times n}$

ALM for (P):

$$-A^T \mathbf{u}^{k+1} \in \partial g(x^{k+1})$$



$$(x^{k+1}, y^{k+1}) = \operatorname{argmin}_{x,y} g(x) + h(y) - \langle u^k, y - Ax \rangle + \frac{\rho}{2} \|Ax - y\|^2$$



$$\mathbf{u}^{k+1} = \mathbf{u}^k + \rho(Ax^{k+1} - y^{k+1})$$

$$\mathbf{u}^{k+1} \in \partial h(x^{k+1})$$



对偶问题(Fenchel Conjugate Dual):

$$\min_u \varphi(u) := g^*(-A^T u) + h^*(u) \quad (\text{D})$$

其中 φ 为适当闭凸函数

最优性分析: $0 \in \partial\varphi(u) \Leftrightarrow 0 \in \rho\partial\varphi(u)$

其他转化方式?

$$\Leftrightarrow u \in u + \rho\partial\varphi(u) = (I + \rho\partial\varphi)(u)$$

$$\Leftrightarrow u = (I + \rho\partial\varphi)^{-1}(u) = \text{prox}_{\rho\varphi}(u)$$

不动点迭代: $u^{k+1} = \text{Prox}_{\rho\varphi}(u^k)$ (Proximal Point Algorithm, PPA)

ALM与PPA

Primal ALM \Leftrightarrow Dual PPA

对偶问题: $\min_u \varphi(u) := g^*(-A^T u) + h^*(u)$ (D)

PPA for (D): $u^{k+1} = \text{Prox}_{\rho\varphi}(u^k)$

$$\begin{aligned} & \updownarrow \\ & u^k - u^{k+1} \in -\rho \left(A \underbrace{\partial g^*(-A^T u^{k+1})}_{x^{k+1}} - \underbrace{\partial h^*(u^{k+1})}_{y^{k+1}} \right) \\ & \updownarrow \\ & u^{k+1} = u^k + \rho(Ax^{k+1} - y^{k+1}) \end{aligned}$$

ALM for (P):

$$\begin{aligned} & \swarrow \quad \searrow \\ & \quad \quad -A^T u^{k+1} \in \partial g(x^{k+1}) \end{aligned}$$

关键性质： 若 g 为适当闭凸函数, 则 $x \in \partial g^*(y) \Leftrightarrow y \in \partial g(x)$

证明: $x \in \partial g^*(y) \Leftrightarrow y \in \operatorname{argmax}_u \{\langle u, x \rangle - g^*(u)\}$

$$\Leftrightarrow g(x) = g^{**}(x) = \langle y, x \rangle - g^*(y)$$

$$\Leftrightarrow g^*(y) = \langle y, x \rangle - g(x)$$

$$\Leftrightarrow y \in \partial g(x)$$

- 凸优化一阶最优性条件
- $g(x) = g^{**}(x)$

不等式约束优化的乘子罚

■ 乘子罚函数【Rockafellar,1973】

$$\begin{aligned}
 \min f(x) \quad (2) \quad & \iff \min f(x) \\
 \text{s.t. } c_i(x) \geq 0, i \in I & \quad \text{s.t. } c_i(x) - s_i = 0, s_i \geq 0, i \in \mathcal{E} \\
 & \quad \Downarrow \text{乘子罚} \\
 & \min_{s \geq 0, x} f(x) - \sum y_i (c_i(x) - s_i) + \frac{\rho}{2} \sum (c_i(x) - s_i)^2 \\
 & = \min_x \min_{s \geq 0} f(x) - \sum y_i (c_i(x) - s_i) + \frac{\rho}{2} \sum (c_i(x) - s_i)^2 \\
 & \quad \Downarrow \\
 & = \min_x L_\rho(x, y) := f(x) + \sum \psi(c_i(x), y_i, \rho)
 \end{aligned}$$

最优解: $s_i = \max\{0, c_i(x) - \frac{y_i}{\rho}\}$

不等式约束优化的乘子罚

■ 乘子罚函数【Rockafellar,1973】

$$\psi(t, \sigma, \rho) = \begin{cases} -\sigma t + \frac{\rho}{2} t^2, & \text{若 } t \leq \frac{\sigma}{\rho} \\ -\frac{\sigma^2}{2\rho}, & \text{其他} \end{cases}$$

称函数 $L_\rho(x, y) = f(x) + \sum \psi(c_i(x), y_i, \rho)$ 为不等式约束优化问题的乘子罚函数, 或增广Lagrange函数.

ALM更新规则

$$\nabla L_{\rho_k}(x^{k+1}, y^k) = \nabla f(x^{k+1}) - \sum_{i \in I, y_i^k - \rho_k c_i(x^{k+1}) \geq 0} [y_i^k - \rho_k c_i(x^{k+1})] \nabla c_i(x^{k+1}) = 0$$

$$\Downarrow$$

$$\nabla f(x^{k+1}) - \sum_{i \in I} [y_i^k - \rho_k c_i(x^{k+1})]_+ \nabla c_i(x^{k+1}) = 0$$

$$\Downarrow$$

$$\nabla f(x^*) - \sum_{i \in \mathcal{E}} y_i^* \nabla c_i(x^*) = 0$$

乘子校正公式

$$y_i^{k+1} = [y_i^k - \rho_k c_i(x^{k+1})]_+$$

算法终止准则: $\|c_i(x^k) - s^k\|_{\infty} \leq \epsilon$

ALM的特点

- 初始点的选取：任意选取
- 迭代过程中的任意点一般是不可行的
- 当迭代点靠近最优解时，随着罚因子的不断增加，子问题的稳定性较好（在一定条件下具有精确罚性质）
- 子问题的精确求解难度

分块结构的约束优化问题:

$$\begin{aligned} \min \quad & f_1(x_1) + f_2(x_2) \\ \text{s. t.} \quad & A_1 x_1 + A_2 x_2 = b \end{aligned} \tag{3}$$

其中, f_1, f_2 为适当闭凸函数, $A_1 \in \mathbb{R}^{p \times n}, A_2 \in \mathbb{R}^{p \times m}, b \in \mathbb{R}^p$

问题结构: 目标函数可分离成两块, 但变量被线性约束结合在一起



例1 复合优化问题

$$\begin{aligned} \min_x f_1(x) + f_2(x) &\iff \min_{x,z} f_1(x) + f_2(z) \\ \text{s.t.} \quad &x - z = 0 \end{aligned}$$

例2 凸集约束优化问题

$$\begin{aligned} \min_x f(x) &\iff \min_{x,z} f(x) + \mathbf{I}_C(z) \\ \text{s.t.} \quad Ax \in C &\quad \text{s.t.} \quad Ax - z = 0 \end{aligned}$$

例3 全局一致性问题 (global consensus problem)

$$\min_x \sum_{i=1}^N f_i(x) \quad \Longleftrightarrow \quad \min_{x_i, z} \sum_{i=1}^N f_i(x_i) \\ \text{s.t.} \quad x_i - z = 0, i = 1, \dots, N$$

例4 共享问题(Sharing problem)

$$\min_{x_i} \sum_{i=1}^N f_i(x_i) + g\left(\sum_{i=1}^N x_i\right) \quad \Longleftrightarrow \quad \min_{x_i, z} \sum_{i=1}^N f_i(x_i) + g\left(\sum_{i=1}^N z_i\right) \\ \text{s.t.} \quad x_i - z_i = 0, i = 1, \dots, N$$

分块结构的约束优化问题:

$$\begin{aligned} \min \quad & f_1(x_1) + f_2(x_2) \\ \text{s. t.} \quad & A_1 x_1 + A_2 x_2 = b \end{aligned} \tag{3}$$

其中: f_1, f_2 为适当闭凸函数, $A_1 \in \mathbb{R}^{p \times n}, A_2 \in \mathbb{R}^{p \times m}, b \in \mathbb{R}^p$

- 增广Lagrange函数:

$$\begin{aligned} L_\rho(x_1, x_2, y) := & f_1(x_1) + f_2(x_2) + y^T (A_1 x_1 + A_2 x_2 - b) \\ & + \frac{\rho}{2} \|A_1 x_1 + A_2 x_2 - b\|_2^2 \end{aligned}$$



ADMM

ALM 迭代



ADMM 迭代

交替极小

$$\begin{cases} (x_1^{k+1}, x_2^{k+1}) = \operatorname{argmin}_{x_1, x_2} L_{\rho_k}(x_1, x_2, y^k) \\ y^k = y^k - \tau \rho_k (A_1 x_1^{k+1} + A_2 x_2^{k+1} - b) \\ \tau \in (0, 2) \end{cases}$$

$$\begin{cases} x_1^{k+1} = \operatorname{argmin}_{x_1} L_{\rho_k}(x_1, x_2^k, y^k) \\ x_2^{k+1} = \operatorname{argmin}_{x_2} L_{\rho_k}(x_1^{k+1}, x_2, y^k) \\ y^k = y^k - \tau \rho_k (A_1 x_1^{k+1} + A_2 x_2^{k+1} - b) \\ \tau \in \left(0, \frac{1 + \sqrt{5}}{2}\right) \end{cases}$$

分块结构的约束优化问题:

$$\begin{aligned} \min \quad & f_1(x_1) + f_2(x_2) \\ \text{s. t.} \quad & A_1 x_1 + A_2 x_2 = b \end{aligned} \tag{3}$$

其中: f_1, f_2 为适当闭凸函数, $A_1 \in \mathbb{R}^{p \times n}, A_2 \in \mathbb{R}^{p \times m}, b \in \mathbb{R}^p$

$$\bullet \text{ KKT 条件 } \begin{cases} 0 \in \partial L(x_1^*, x_2^*, y^*) = \begin{pmatrix} \partial f_1(x_1^*) + A_1^T y^* \\ \partial f_2(x_2^*) + A_2^T y^* \end{pmatrix} \\ A_1 x_1^* + A_2 x_2^* = b \end{cases} \tag{4}$$

其中: $L(x_1, x_2, y) := f_1(x_1) + f_2(x_2) + y^T(A_1 x_1 + A_2 x_2 - b)$ 为 Lagrange 函数.

最优性条件

定理2 设凸优化问题(3)满足Slater条件

$$\exists (\mathbf{x}_1^0, \mathbf{x}_2^0) \in \text{int dom } f_1 \times \text{int dom } f_2 \quad \text{s.t.} \quad A_1 \mathbf{x}_1^0 + A_2 \mathbf{x}_2^0 = \mathbf{b}$$

成立. 则任意最优解 \mathbf{x}^* 均为(3)的KKT点,即存在 $\mathbf{y}^* \in \mathbb{R}^p$ 使得 $(\mathbf{x}^*, \mathbf{y}^*)$ 满足KKT条件(4).

- KKT点与最优解等价 (在Slater条件下)
- KKT条件可用于设置算法停机准则与分析收敛性

最优性分析


$$\begin{aligned} \min \quad & f_1(x_1) + f_2(x_2) \\ \text{s. t.} \quad & A_1 x_1 + A_2 x_2 = b \end{aligned} \quad (3)$$



$$\begin{aligned} \min \quad & f(x_1, x_2) := f_1(x_1) + f_2(x_2) + \mathbf{I}_\Omega(x_1, x_2) \implies (0, 0) \in \partial f(x_1^*, x_2^*) \\ \Omega := \quad & \{(x_1, x_2) : A_1 x_1 + A_2 x_2 = b\} \end{aligned}$$

$$\begin{aligned} & \begin{cases} \begin{pmatrix} 0 \\ 0 \end{pmatrix} \in \begin{pmatrix} \partial f_1(x_1^*) + A_1^T y^* \\ \partial f_2(x_2^*) + A_2^T y^* \end{pmatrix} \\ A_1 x_1^* + A_2 x_2^* = b \end{cases} \\ & \quad \quad \quad \uparrow \\ & \begin{pmatrix} 0 \\ 0 \end{pmatrix} \in \begin{pmatrix} \partial f_1(x_1^*) \\ \partial f_2(x_2^*) \end{pmatrix} + \boxed{\partial \mathbf{I}_\Omega(x_1^*, x_2^*)} \\ & \quad \quad \quad \uparrow \text{Slater} \end{aligned}$$

对偶问题

$$\begin{aligned}
 & \sup_{\mathbf{y} \in \mathbb{R}^p} \{\vartheta(\mathbf{y}) := \inf_{x_1, x_2} L(x_1, x_2, \mathbf{y})\} \\
 &= -\inf_{\mathbf{y} \in \mathbb{R}^p} \underbrace{\mathbf{b}^T \mathbf{y} + f_1^*(-A_1^T \mathbf{y})}_{f(\mathbf{y})} + \underbrace{f_2^*(-A_2^T \mathbf{y})}_{h(\mathbf{y})} \tag{5}
 \end{aligned}$$


$$\begin{aligned}
 & \inf_{x_1, x_2} L(x_1, x_2, \mathbf{y}) \\
 &= \inf_{x_1} \{f_1(x_1) + \mathbf{y}^T A_1 x_1\} + \inf_{x_2} \{f_2(x_2) + \mathbf{y}^T A_2 x_2\} - \mathbf{b}^T \mathbf{y} \\
 &= -\sup_{x_1} \{\langle -A_1^T \mathbf{y}, x_1 \rangle - f_1(x_1)\} - \sup_{x_2} \{\langle -A_2^T \mathbf{y}, x_2 \rangle - f_2(x_2)\} - \mathbf{b}^T \mathbf{y} \\
 &= -f_1^*(-A_1^T \mathbf{y}) - f_2^*(-A_2^T \mathbf{y}) - \mathbf{b}^T \mathbf{y}
 \end{aligned}$$

最优性条件

定理3 设 $(\mathbf{x}^*, \mathbf{y}^*)$ 满足KKT条件(4), 则 \mathbf{x}^* 为原问题(3)的最优解, \mathbf{y}^* 为对偶问题(5)的最优解.

分析

$$0 \in T(\mathbf{x}_1^*, \mathbf{x}_2^*, \mathbf{y}^*)$$



KKT
系统
(4)

$$\begin{cases} -A_1^T \mathbf{y}^* \in \partial f_1(\mathbf{x}_1^*) \\ -A_2^T \mathbf{y}^* \in \partial f_2(\mathbf{x}_2^*) \\ A_1 \mathbf{x}_1^* + A_2 \mathbf{x}_2^* = \mathbf{b} \end{cases}$$

$$\Leftrightarrow \begin{cases} \mathbf{x}_1^* \in \partial f_1^*(-A_1^T \mathbf{y}^*) \\ \mathbf{x}_2^* \in \partial f_2^*(-A_1^T \mathbf{y}^*) \end{cases}$$

KKT系统of (5)

$$\Rightarrow 0 \in \partial f(\mathbf{y}^*) + \partial h(\mathbf{y}^*)$$